



ระบบตรวจจับวัตถุต้องห้ามในภาพเอกซเรย์

นายณภัทร เนื้อเย็น

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรวิทยาศาสตรบัณฑิต
สาขาวิชาเทคโนโลยีสารสนเทศ ภาควิชาเทคโนโลยีสารสนเทศ
คณะเทคโนโลยีและการจัดการอุตสาหกรรม มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ
ปีการศึกษา 2569
ลิขสิทธิ์ของมหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ

ระบบตรวจจับวัตถุต้องห้ามในภาพเอกซเรย์

นายณภัทร เนื้อเย็น

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรวิทยาศาสตรบัณฑิต
สาขาวิชาเทคโนโลยีสารสนเทศ ภาควิชาเทคโนโลยีสารสนเทศ
คณะเทคโนโลยีและการจัดการอุตสาหกรรม มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ
ปีการศึกษา 2569
ลิขสิทธิ์ของมหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ

PROHIBITED ITEM DETECTION SYSTEM FOR X-RAY IMAGES

MR.NAPAT NUEYEN

PROJECT REPORT SUBMITTED IN PARTIAL FULFILLMENT OF THE REQUIREMENTS
FOR THE BACHELOR'S DEGREE OF SCIENCE PROGRAM IN INFORMATION TECHNOLOGY
FACULTY OF INDUSTRIAL TECHNOLOGY AND MANAGEMENT
KING MONGKUT'S UNIVERSITY OF TECHNOLOGY NORTH BANGKOK
ACADEMIC YEAR 2026
COPYRIGHT OF KING MONGKUT'S UNIVERSITY OF TECHNOLOGY NORTH BANGKOK



ใบรับรองปริญญาโท
คณะเทคโนโลยีและการจัดการอุตสาหกรรม
มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ

เรื่อง ระบบตรวจจับวัตถุต้องห้ามในภาพเอกซเรย์
โดย นายณภัทร เนื่อเย็น

ได้รับอนุมัติให้เป็นส่วนหนึ่งของการศึกษาตาม
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาเทคโนโลยีสารสนเทศ

_____ คนบดี
(.....)
_____ ประธานกรรมการ
(.....)
_____ กรรมการ
(.....)
_____ กรรมการ
(.....)

ชื่อ : นายนภัทร เนื้อเย็น
ชื่อปริญญาบัตร : ระบบตรวจจับวัตถุต้องห้ามในภาพเอกซเรย์
สาขาวิชา : เทคโนโลยีสารสนเทศ
: มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ
อาจารย์ที่ปรึกษาปริญญาบัตร : ผู้ช่วยศาสตราจารย์ ดร.วันที ประจวบศุภกิจ
ปีการศึกษา : 2569

บทคัดย่อ

ปริญญาบัตรฉบับนี้มีวัตถุประสงค์เพื่อศึกษาและพัฒนาระบบตรวจจับวัตถุต้องห้ามในภาพเอกซเรย์ โดยแบ่งการดำเนินงานออกเป็น 2 ระยะตามแผนการศึกษา 2 เทอม ระยะที่ 1 มุ่งเน้นการเตรียมข้อมูล ฝึกสอน ประเมิน และเปรียบเทียบโมเดลการเรียนรู้เชิงลึกหลายสถาปัตยกรรม ได้แก่ EfficientNet, ResNet50, VGG16, RT-DETR และ YOLOv11 บนชุดข้อมูล X-ray FSOD ที่จัดเตรียมเป็นรูปแบบ COCO จำนวน 20 คลาส ส่วนระยะที่ 2 เป็นการนำโมเดลที่คัดเลือกไปพัฒนาเป็นระบบใช้งานจริงผ่านเว็บแอปพลิเคชัน รวมถึงฟังก์ชันการอัปโหลดภาพ การแสดงผลตำแหน่งวัตถุ การตัดสินใจผ่านหรือไม่ผ่าน และการส่งออกรายงาน

ผลการทดลองในเทอมแรกพบว่า YOLOv11-1 ให้ค่า F1 ที่ confidence 0.25 และ IoU 0.50 เท่ากับ 0.7847 ค่า macro F1 เท่ากับ 0.7538 และ AP@0.50 เท่ากับ 0.7702 จึงเหมาะสมสำหรับนำไปเป็นโมเดลหลักของระบบในเทอมที่ 2 แม้ RT-DETR จะมีค่า mAP@0.50:0.95 สูงกว่าเล็กน้อย แต่เมื่อพิจารณาความสมดุลระหว่าง precision, recall, F1 และความพร้อมของเครื่องมือ deploy แล้ว YOLOv11 เป็นตัวเลือกที่เหมาะสมกับระบบต้นแบบมากที่สุด

คำสำคัญ: ภาพเอกซเรย์, การตรวจจับวัตถุ, วัตถุต้องห้าม, YOLOv11, RT-DETR, COCO, Streamlit

(ปริญญาบัตรนี้มีความยาวทั้งหมด 22 หน้า)

อาจารย์ที่ปรึกษา
ปริญญาบัตร

Name : Mr. Napat Nueyen
Project Title : Prohibited Item Detection System for X-ray Images
Field of Study : Information Technology
: King Mongkut'S University Of Technology North Bangkok
Project Advisor : Asst. Prof. Dr. Wantanee Prachuapsupakit
Academic Year : 2569

Abstract

This thesis studies and develops a prohibited item detection system for X-ray images. The project is organized into two semesters. The first semester focuses on dataset preparation, training, evaluation, and model comparison across EfficientNet, ResNet50, VGG16, RT-DETR, and YOLOv11. The second semester extends the selected model into a practical prototype with image upload, visual detection, pass/fail decision, and report export functions.

The first-semester results show that YOLOv11-1 achieves the highest overall F1 score of 0.7847 at confidence 0.25 and IoU 0.50, with macro F1 of 0.7538 and AP@0.50 of 0.7702. Although RT-DETR obtains slightly higher mAP@0.50:0.95, YOLOv11 is selected as the main model for the second-semester system due to its balanced F1 performance and deployment readiness.

Keywords: X-ray images, object detection, prohibited items, YOLOv11, RT-DETR, COCO

(Total 22 pages)

Project Advisor

กิตติกรรมประกาศ

ปริญญานิพนธ์ฉบับนี้สำเร็จลุล่วงได้ด้วยความรู้และคำแนะนำจากอาจารย์ที่ปรึกษาปริญญานิพนธ์ ซึ่งได้ให้ข้อเสนอแนะในการกำหนดขอบเขต การตรวจสอบผลการทดลอง และการเรียบเรียงรายงาน ผู้จัดทำขอกราบขอบพระคุณเป็นอย่างสูง

ขอขอบคุณคณาจารย์และเพื่อนนักศึกษาคณะศึกษาศาสตร์เทคโนโลยีสารสนเทศที่ให้ข้อคิดเห็นและกำลังใจตลอดการดำเนินโครงการ รวมทั้งผู้พัฒนาชุดข้อมูลและเครื่องมือโอเพนซอร์สที่ใช้ในการทดลอง

นายณภัทร เนื้อเย็น

นายณภัทร เนื้อเย็น

บทคัดย่อ.....	ข
Abstract.....	ค
กิตติกรรมประกาศ.....	ง
สารบัญ.....	จ
สารบัญภาพ.....	ฉ
สารบัญตาราง.....	ช
บทที่ 1 บทนำ.....	1
บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง.....	3
บทที่ 3 วิธีดำเนินงาน.....	6
บทที่ 4 ผลการดำเนินงาน.....	10
บทที่ 5 สรุปผลและข้อเสนอแนะ.....	14
บรรณานุกรม.....	16
ภาคผนวก.....	17

ภาพที่	สารบัญภาพ	หน้า
2-1	ภาพรวมโมเดลกลุ่ม CNN ที่ใช้ในการศึกษา	
2-2	ภาพรวมโมเดลตรวจจับวัตถุ YOLOv11 และ RT-DETR	
3-1	ภาพรวมกระบวนการทำงานของระบบ	
4-1	กราฟเปรียบเทียบผลรวมของโมเดล	
4-2	ค่า F1 ที่ดีที่สุดจากการปรับ threshold	

สารบัญตาราง

ตารางที่

หน้า

- 2-1 งานวิจัยและเอกสารที่เกี่ยวข้อง
- 3-1 การแบ่งชุดข้อมูล X-ray FSOD
- 3-2 โมเดลที่ใช้เปรียบเทียบ
- 4-1 ผลการเปรียบเทียบโมเดล
- 4-2 ผลการปรับ confidence threshold
- 4-3 ผลรายคลาสของโมเดลที่เลือก
- 5-1 แผนการดำเนินงานภาคการศึกษาที่ 2

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

การตรวจสอบภาพด้วยภาพเอกซเรย์เป็นกระบวนการสำคัญของงานรักษาความปลอดภัยในสนามบินและพื้นที่ควบคุม อย่างไรก็ตาม ภาพเอกซเรย์มีความซับซ้อนจากการซ้อนทับของวัตถุ รูปร่างที่เปลี่ยนไปตามมุมมอง สีที่สัมพันธ์กับวัสดุ และจำนวนสิ่งของจำนวนมากในกระเป๋า ส่งผลให้การพิจารณาด้วยสายตามีโอกาสเกิดความล่าและความคลาดเคลื่อน งานนี้จึงนำเทคนิคการเรียนรู้เชิงลึกมาช่วยตรวจสอบตำแหน่งและประเภทของวัตถุต้องห้ามจากภาพเอกซเรย์

โครงการเปรียบเทียบโมเดลหลายสถาปัตยกรรมภายใต้ชุดทดสอบเดียวกัน เพื่อใช้ผลการทดลองประกอบการคัดเลือกโมเดลสำหรับต้นแบบในตอนที่ 2 โดยไม่มุ่งหมายให้เป็นระบบที่พร้อมใช้งานจริง.

1.2 วัตถุประสงค์

เพื่อจัดเตรียมชุดข้อมูล X-ray FSOD ให้อยู่ในรูปแบบที่ใช้ฝึกและประเมินโมเดลตรวจจับวัตถุได้.

เพื่อฝึกและประเมินโมเดล EfficientNet, ResNet50, VGG16, RT-DETR และ YOLOv11 ภายใต้เงื่อนไขการทดสอบเดียวกัน.

เพื่อเปรียบเทียบผลด้วย precision, recall, F1, macro F1, mAP, AP@0.50 และ threshold sweep.

เพื่อคัดเลือกโมเดลที่เหมาะสมสำหรับพัฒนาเป็นระบบต้นแบบในตอนที่ 2 ซึ่งรองรับผู้ใช้และผู้ดูแลระบบ การบันทึกผลตรวจ และการคัดเลือกข้อมูลสำหรับการฝึกโมเดลในรอบถัดไป.

1.3 ขอบเขตการดำเนินงาน

ตอนที่ 1 ครอบคลุมการเตรียมข้อมูล การฝึกโมเดล การสร้างผลทำนายบนชุดทดสอบ การประเมินผล และการจัดทำ dashboard สำหรับเปรียบเทียบโมเดล.

ตอนที่ 2 ครอบคลุมการพัฒนาแบบต้นแบบที่รองรับผู้ใช้และผู้ดูแลระบบ การอัปโหลดภาพหรือรับภาพจากกล้อง การเรียกใช้โมเดลที่คัดเลือก การบันทึกภาพและผลตรวจพร้อมรุ่นของโมเดล และการแสดงผลตรวจจับหลายวัตถุ.

ระบบจะใช้ Supabase Free สำหรับการยืนยันตัวตน ฐานข้อมูล และการเก็บไฟล์ภายในขอบเขตการทดลอง โดยผู้ใช้งานต้องยินยอมก่อนบันทึกภาพ ผู้ดูแลระบบสามารถตรวจสอบ คัดเลือก หรือแก้ไขข้อมูลผลตรวจ และส่งออกเฉพาะรายการที่ผ่านการตรวจเพื่อนำไปจัดทำชุดข้อมูลและฝึกโมเดลแบบออฟไลน์ในรอบถัดไป ทั้งนี้ไม่รวมการเทรนอัตโนมัติ การเปลี่ยนโมเดลอัตโนมัติ การเชื่อมต่อระบบรักษาความปลอดภัย หรือการใช้งานจริงเชิงปฏิบัติการ.

1.4 ประโยชน์ที่คาดว่าจะได้รับ

ได้ผลการเปรียบเทียบโมเดลจากข้อมูลและตัวชี้วัดเดียวกัน เพื่อใช้เป็นข้อมูลประกอบการเลือกโมเดลภายในขอบเขตของโครงการ.

ได้แนวทางระบบต้นแบบที่แบ่งสิทธิ์ผู้ใช้และผู้ดูแลระบบ บันทึกผลตรวจอย่างเป็นระบบ และสร้างรายการข้อมูลที่ผ่านการตรวจเพื่อใช้เป็นข้อมูลตั้งต้นสำหรับการฝึกโมเดลในรอบถัดไป.

บทที่ 2

แนวคิด ทฤษฎี และงานวิจัยที่เกี่ยวข้อง


2.1 การตรวจจับวัตถุจากภาพเอกซเรย์

ปัญหาการตรวจจับวัตถุต้องห้ามในภาพเอกซเรย์แตกต่างจากภาพทั่วไป เนื่องจากมีการซ้อนทับของวัตถุ วัตถุมีขนาดเล็กหรือรูปร่างใกล้เคียงกับสิ่งของปกติ และสีในภาพเอกซเรย์สะท้อนคุณสมบัติของวัสดุมากกว่าสีจริง ชุดข้อมูลด้าน X-ray security เช่น OPIXray และ PIDray ถูกนำเสนอเพื่อกระตุ้นงานวิจัยในโจทย์นี้โดยเฉพาะ

2.2 Convolutional Neural Networks

CNN เป็นโครงข่ายที่ใช้ convolutional layer เพื่อเรียนรู้คุณลักษณะเชิงพื้นที่ของภาพ โมเดล VGG, ResNet และ EfficientNet เป็นตัวแทนของแนวคิด CNN คนละยุค ได้แก่ การเพิ่มความลึกด้วย convolution ขนาดเล็ก การใช้ residual connection และการ scale ความลึก ความกว้าง และความละเอียดอย่างสมดุล

ภาพที่ 2-1 แสดงภาพรวมการไหลของข้อมูลของโมเดลกลุ่ม CNN ที่ใช้ในการศึกษา โดย VGG16 เน้นการซ้อนชั้น convolution, ResNet50 ใช้ residual connection และ EfficientNet ใช้ MBConv ร่วมกับการปรับขนาดโมเดลแบบ compound scaling (Simonyan & Zisserman, 2015; He et al., 2015; Tan & Le, 2019).




ภาพที่ 2-1 ภาพรวมโมเดลกลุ่ม CNN ที่ใช้ในการศึกษา

2.3 YOLO และ RT-DETR

YOLO เป็นกลุ่มโมเดล real-time object detection ที่นิยมใช้ในระบบต้นแบบเพราะมีเครื่องมือฝึก ประเมิน และ deploy ที่ครบถ้วน ส่วน RT-DETR เป็นแนวทาง detection transformer ที่ออกแบบมาเพื่อลดข้อจำกัดด้านความเร็วของ DETR และยังคงประสิทธิภาพสูง การเปรียบเทียบทั้งสองแนวทางจึงช่วยให้เห็นความต่างระหว่างโมเดลสาย CNN/one-stage detector กับ transformer detector

ภาพที่ 2-2 แสดงองค์ประกอบหลักของโมเดลตรวจจับวัตถุที่ใช้ในการศึกษา โดย YOLOv11 ประกอบด้วย backbone, neck และ detection head ส่วน RT-DETR ใช้ CNN backbone, hybrid encoder และ transformer decoder เพื่อทำนายกรอบวัตถุและคลาส (Ultralytics, 2026; Zhao et al., 2023).



ภาพที่ 2-2 ภาพรวมโมเดลตรวจจับวัตถุ YOLOv11 และ RT-DETR

2.4 Metric สำหรับ Object Detection

งานนี้ใช้ precision เพื่อวัดความถูกต้องของวัตถุที่ตรวจพบ, recall เพื่อวัดความครอบคลุมของวัตถุจริง, F1 เพื่อวัดสมดุลระหว่าง precision และ recall, macro F1 เพื่อสะท้อนผลเฉลี่ยรายคลาส, และ mAP/AP ตามแนวทาง COCO เพื่อวัดคุณภาพการตรวจจับในหลายระดับ IoU

2.5 งานวิจัยและแหล่งอ้างอิงหลัก

หัวข้อ	ผู้เสนอ	บทบาทในงานนี้
VGG	Simonyan และ Zisserman	ศึกษาผลของความลึกของ CNN โดยใช้ convolution 3x3
ResNet	He และคณะ	เสนอ residual learning เพื่อฝึกโครงข่ายลึกได้ง่ายขึ้น
EfficientNet	Tan และ Le	เสนอ compound scaling เพื่อเพิ่มประสิทธิภาพของ CNN
RT-DETR	Zhao และคณะ	เสนอ Real-Time Detection Transformer สำหรับ real-time detection
COCO	Lin และคณะ	เป็นมาตรฐาน annotation/evaluation ที่ใช้ใน object detection

บทที่ 3

วิธีการดำเนินงาน

3.1 ภาพรวมระบบ

กระบวนการดำเนินงานเริ่มจากการเตรียมชุดข้อมูล X-ray FSOD จำนวน 20 คลาส แปลงให้อยู่ในรูปแบบ COCO จากนั้นฝึกและประเมินโมเดลหลายสถาปัตยกรรม สร้างผลลัพธ์การทำนายเป็นไฟล์ JSON แล้วนำเข้าสู่ระบบเปรียบเทียบโมเดล เพื่อคำนวณ metric และสร้างรายงานผล เมื่อได้โมเดลที่เหมาะสมจะนำไปต่อยอดในเว็บแอปพลิเคชันเทอมที่ 2

Dataset	Preprocess	Train / Evaluate	Model Selection	Term 2 System
X-ray FSOD 20 classes	COCO JSON train/val/test	EfficientNet, ResNet50, VGG16, RT-DETR, YOLOv11	F1, mAP, AP@0.50, threshold sweep	Web prototype, user/admin roles, Supabase data storage, review and dataset export

ภาพที่ 3.1 ภาพรวมกระบวนการทำงานของระบบ

ชุดข้อมูลที่จัดเตรียมแล้วประกอบด้วย train 8,880 ภาพ, validation 987 ภาพ และ test 2,466 ภาพ

3.2 ชุดข้อมูล

ชุดข้อมูล	จำนวนภาพ	จำนวน annotation
train	8,880	30,386
val	987	3,322
test	2,466	7,996
รวม	12,333	41,704

รายชื่อคลาสที่ใช้ประกอบด้วย laptop, lighter, portable_charger_2, iron_shoe, straight_knife, folding_knife, scissor, multi-tool_knife, umbrella, glass_bottle, battery, metal_cup, nail_clippers, pressure_tank, spray_alcohol, portable_charger_1, utility_knife, mobile_phone, metal_can, drink_bottle.

3.3 การกำหนดเงื่อนไขการประเมิน

ใช้ ground-truth JSON ไฟล์เดียวกัน คือ

xrayfsod_outputs/_prepared_full20/annotations/test.json

ใช้ confidence threshold เริ่มต้น 0.25, IoU threshold 0.50 และ max detections per image เท่ากับ 100

ใช้ threshold sweep ตั้งแต่ 0.05 ถึง 0.90 เพื่อดูผลของการปรับ confidence ต่อ F1

ประเมินทุกโมเดลด้วย metric ชุดเดียวกันผ่าน evaluator.py และแสดงผลผ่าน Streamlit dashboard

3.4 โมเดลที่ใช้เปรียบเทียบ

โมเดล	Run ID	Confidence	IoU
YOLOv11-1	YOLOv11-1	0.25	0.5
RT-DETR-1	RT-DETR-1	0.25	0.5
VGG16-4	VGG16-4	0.25	0.5
EfficientNet-1	EfficientNet-1	0.25	0.5
ResNet50-1	ResNet50-1	0.25	0.5

3.5 ฟังก์ชันระบบที่พัฒนาแล้วและแผนต่อยอด


ในโฟลเดอร์ model_comparison มีเว็บ dashboard สำหรับดูรายงานผลเปรียบเทียบโมเดลแบบ read-only และโหมด local สำหรับประเมินโมเดลจากไฟล์ prediction จริง ส่วนโฟลเดอร์ webapp มีต้นแบบ Streamlit สำหรับอัปโหลดภาพ X-ray โหลดน้ำหนักโมเดล YOLO แสดง mask/bounding box แสดงรายการวัตถุที่พบ และดาวน์โหลดผลลัพธ์เป็น JSON

บทที่ 4
ผลการดำเนินงาน


4.1 ผลการเปรียบเทียบโมเดลที่ threshold เริ่มต้น

อันดับ	โมเดล	Precision	Recall	F1	Macro F1	mAP	AP@0.50
1	YOLOv11-1	0.7775	0.7921	0.7847	0.7538	0.5441	0.7702
2	RT-DETR-1	0.5785	0.8583	0.6911	0.6708	0.5490	0.7740
3	VGG16-4	0.4011	0.8268	0.5402	0.5264	0.4289	0.6893
4	EfficientNet-1	0.2656	0.7225	0.3884	0.3734	0.3059	0.5164
5	ResNet50-1	0.2574	0.7276	0.3802	0.3685	0.3019	0.5115

ผลลัพธ์แสดงว่า YOLOv11-1 ได้ F1 สูงที่สุดที่ 0.7847 โดยมี precision 0.7775 และ recall 0.7921 แสดงถึงความสมดุลที่ดีกว่าระหว่างการตรวจเจอวัตถุจริงและการลดผลบวกผิดพลาด เมื่อเทียบกับ RT-DETR ซึ่งมี recall สูงกว่าและ mAP สูงกว่าเล็กน้อย แต่มี precision ต่ำกว่า ทำให้ F1 รวมที่ threshold เดียวกันต่ำกว่า



ภาพที่ 4.1 กราฟเปรียบเทียบผลรวมของโมเดล



ภาพที่ 4.2 ค่า F1 ที่ดีที่สุดจากการปรับ threshold

4.2 ผลการปรับ confidence threshold

โมเดล	Threshold ที่ดีที่สุด	Precision	Recall	F1	Macro F1
RT-DETR-1	0.6	0.8408	0.7658	0.8015	0.7551
YOLOv11-1	0.4	0.8408	0.7646	0.8009	0.7630
VGG16-4	0.8	0.7856	0.6861	0.7325	0.6736
EfficientNet-1	0.8	0.7627	0.4967	0.6016	0.4969
ResNet50-1	0.7	0.6661	0.5430	0.5983	0.4980

เมื่อปรับ threshold พบว่า YOLOv11 และ RT-DETR มีค่า best F1 ใกล้เคียงกันมาก โดย RT-DETR สูงกว่าเล็กน้อยในค่า best F1 แต่ YOLOv11 มีผลที่ threshold เริ่มต้นดีกว่าและมีความพร้อมต่อการนำไปใช้งานในเว็บแอปมากกว่า จึงเลือก YOLOv11 เป็นโมเดลหลักของเทอมที่ 2

4.3 ผลรายคลาสของโมเดลที่เลือก

คลาส	Precision	Recall	F1	จำนวนวัตถุจริงใน test
metal_cup	0.9236	0.9647	0.9437	539
laptop	0.8845	0.9728	0.9265	551
umbrella	0.8559	0.9309	0.8918	434
mobile_phone	0.8417	0.9085	0.8738	1071

คลาส	Precision	Recall	F1	จำนวนวัตถุจริงใน test
multi-tool_knife	0.7775	0.9187	0.8422	369
scissor	0.8846	0.8023	0.8415	258
portable_charger _2	0.8083	0.8649	0.8356	385
portable_charger _1	0.7877	0.8725	0.8280	353
pressure_tank	0.7870	0.8380	0.8117	216
nail_clippers	0.8421	0.6978	0.7632	321

ผลรวมคลาสช่วยชี้ให้เห็นว่าโมเดลไม่ได้มีประสิทธิภาพเท่ากันทุกประเภทวัตถุ คลาสที่มีลักษณะชัดเจน
หรือมีจำนวนตัวอย่างมากมักได้ F1 สูงกว่า ขณะที่วัตถุขนาดเล็กหรือซ้อนทับกับสิ่งของอื่น เช่น lighter หรือ
folding_knife มีความท้าทายสูงกว่าและควรใช้เป็นจุดปรับปรุงในเทอมถัดไป

บทที่ 5

สรุปผลการดำเนินงาน และข้อเสนอแนะ

5.1 สรุปผลเทอมที่ 1

เทอมที่ 1 บรรลุเป้าหมายหลักในการจัดเตรียมข้อมูล ฝึกและประเมินโมเดลหลายสถาปัตยกรรม สร้างระบบ dashboard สำหรับเปรียบเทียบผล และคัดเลือกโมเดลสำหรับนำไปต่อยอด ผลการทดลองชี้ว่า YOLOv11-1 เป็นตัวเลือกที่เหมาะสมที่สุดสำหรับระบบต้นแบบ เนื่องจากให้ F1 รวมสูงสุดที่ threshold เริ่มต้น และมีเครื่องมือรองรับการนำไปใช้งานจริงผ่าน Ultralytics และ Streamlit

5.2 แผนดำเนินงานเทอมที่ 2

ลำดับ	งาน	รายละเอียด	ผลลัพธ์
1	ระบบผู้ใช้และสิทธิ์	สมัครและเข้าสู่ระบบผ่าน Supabase Auth พร้อมแยกสิทธิ์ user และ admin	เข้าถึงระบบตามสิทธิ์
2	ตรวจจับและบันทึกผล	รับภาพจากการอัปโหลด หรือกล้อง เรียกใช้ YOLOv11 และบันทึกภาพ ผลตรวจ เวลา และรุ่นโมเดลหลังผู้ใช้ยินยอม	ประวัติผลตรวจ
3	จัดเก็บข้อมูล	ใช้ Supabase Database และ Storage เก็บข้อมูลผลตรวจ ไฟล์ภาพ และสถานะการตรวจสอบ ภายในโควตาแผนฟรี	ข้อมูลต้นแบบส่วนกลาง
4	แดชบอร์ดและการตรวจสอบ	แสดงสถิติผู้ใช้ การอัปโหลด คลาสที่ตรวจพบ และคิวให้แอดมินยืนยันปฏิเสธ หรือแก้ไขคลาสของผลตรวจ	แดชบอร์ดแอดมิน
5	จัดการรุ่นโมเดลและชุดข้อมูล	ส่งออกข้อมูลที่แอดมินอนุมัติ ฝึกและประเมินแบบออฟไลน์ แล้วให้แอดมินเลือกใช้เฉพาะรุ่นที่ผ่านการประเมิน	ชุดข้อมูลและรุ่นโมเดลที่ผ่านการประเมิน

5.3 ข้อจำกัดและข้อเสนอแนะ

ควรทดสอบ inference time บน hardware เป้าหมายเดียวกันเพื่อเปรียบเทียบความเร็วอย่างเป็นธรรม

ควรเพิ่มข้อมูลหรือ augmentation สำหรับคลาสที่มี F1 ต่ำและวัตถุที่มีการซ้อนทับสูง

ควรตรวจสอบ false positive จากวัตถุที่มีรูปร่างคล้ายวัตถุต้องห้ามก่อนนำไปใช้ในสภาพแวดล้อมจริง

ควรกำหนดขั้นตอน human-in-the-loop ให้เจ้าหน้าที่ตรวจยืนยันผลเมื่อระบบแจ้งเตือน

เอกสารอ้างอิง

- Simonyan, K., & Zisserman, A. (2015). Very Deep Convolutional Networks for Large-Scale Image Recognition. arXiv:1409.1556. <https://arxiv.org/abs/1409.1556>
- He, K., Zhang, X., Ren, S., & Sun, J. (2015). Deep Residual Learning for Image Recognition. arXiv:1512.03385. <https://arxiv.org/abs/1512.03385>
- Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. arXiv:1905.11946. <https://arxiv.org/abs/1905.11946>
- Zhao, Y., Lv, W., Xu, S., et al. (2023). DETRs Beat YOLOs on Real-time Object Detection. arXiv:2304.08069. <https://arxiv.org/abs/2304.08069>
- Ultralytics. (2026). Ultralytics YOLO11 Documentation. <https://docs.ultralytics.com/models/yolo11>
- Lin, T.-Y., Maire, M., Belongie, S., et al. (2014). Microsoft COCO: Common Objects in Context. arXiv:1405.0312. <https://arxiv.org/abs/1405.0312>
- Wei, Y., Tao, R., Wu, Z., et al. (2020). Occluded Prohibited Items Detection: An X-ray Security Inspection Benchmark. arXiv:2004.08656. <https://arxiv.org/abs/2004.08656>
- Zhang, L., Jiang, L., Ji, R., & Fan, H. (2022). PIDray: A Large-scale X-ray Benchmark for Real-World Prohibited Item Detection. arXiv:2211.10763. <https://arxiv.org/abs/2211.10763>

ภาคผนวก

ภาคผนวก ก

ผลรายคลาสทั้งหมดของโมเดลที่เลือก

ID	คลาส	Precision	Recall	F1	จำนวนวัตถุจริง
1	laptop	0.8845	0.9728	0.9265	551
2	lighter	0.6880	0.4859	0.5695	177
3	portable_charger_2	0.8083	0.8649	0.8356	385
4	iron_shoe	0.8171	0.6774	0.7407	310
5	straight_knife	0.7120	0.7043	0.7081	186
6	folding_knife	0.5526	0.3889	0.4565	54
7	scissor	0.8846	0.8023	0.8415	258
8	multi-tool_knife	0.7775	0.9187	0.8422	369
9	umbrella	0.8559	0.9309	0.8918	434
10	glass_bottle	0.7248	0.7355	0.7301	605
11	battery	0.6255	0.6508	0.6379	965
12	metal_cup	0.9236	0.9647	0.9437	539
13	nail_clippers	0.8421	0.6978	0.7632	321
14	pressure_tank	0.7870	0.8380	0.8117	216
15	spray_alcohol	0.7104	0.5274	0.6054	493
16	portable_charger_1	0.7877	0.8725	0.8280	353
17	utility_knife	0.6965	0.7865	0.7388	178
18	mobile_phone	0.8417	0.9085	0.8738	1071
19	metal_can	0.6884	0.7570	0.7211	391
20	drink_bottle	0.5679	0.6571	0.6093	140

ภาคผนวก ข โครงสร้างไฟล์สำคัญของโปรเจกต์

ไฟล์/โฟลเดอร์	หน้าที่
model_comparison/app.py	เว็บ dashboard สำหรับเปรียบเทียบโมเดล
model_comparison/evaluator.py	คำนวณ metric และสร้างกราฟผลการทดลอง

ไฟล์/โฟลเดอร์	หน้าที่
model_comparison/results/summary.csv	ผลสรุปโมเดลทุกตัว
xrayfsod_outputs/_prepared_full20/ annotations/test.json	ground truth สำหรับชุดทดสอบ
webapp/app.py	ต้นแบบเว็บแอปตรวจภาพ X-ray ด้วยโมเดล YOLO
later_after_training.md	รายการพัฒนาระบบผู้ใช้ แอดมิน การคัดกรองข้อมูล และการจัดทำชุดข้อมูลสำหรับรอบฝึกถัดไป